



# MASTÈRE SPÉCIALISÉ INTELLIGENCE ARTIFICIELLE

IA 716  
COMPUTER VISION

---

## Géométrie Algorithmique & Morphologie mathématique

---


*Réalisé par:*

Maxime LEDIEU  
Edouard DUCLOY

*Enseignant :*

Gianni FRANCHI

29 février 2024



# Table des matières

<b>1</b>	<b>Introduction</b>	<b>2</b>
1.1	Contexte et objectif . . . . .	2
1.2	Données . . . . .	2
1.3	Métrie d'évaluation . . . . .	4
<b>2</b>	<b>Opérations</b>	<b>5</b>
2.1	Augmentation du contraste . . . . .	5
2.2	Filtre de Gabor . . . . .	5
2.3	Ouvertures . . . . .	6
2.4	Black Top-Hats . . . . .	7
2.5	Erosions . . . . .	7
2.6	Reconstruction . . . . .	8
2.7	Filtre gaussien . . . . .	8
2.8	Segmentation . . . . .	9
2.9	Premiers résultats . . . . .	9
<b>3</b>	<b>Optimisations</b>	<b>11</b>
3.1	Méthodologie initiale pour l'optimisation : Affinage des Hyperparamètres avec Optuna . . . . .	11
3.2	Considérations sur le choix des hyperparamètres . . . . .	11
3.3	Affinage progressif des hyperparamètres . . . . .	11
3.4	Résultats . . . . .	12
3.5	Exploration et Tests de Méthodes Supplémentaires . . . . .	12
3.6	Post-traitement et amélioration finale . . . . .	13
3.7	Extension de l'Optimisation aux Autres Images . . . . .	13
3.8	Optimisation Globale des Hyperparamètres . . . . .	13
<b>4</b>	<b>Résultats finaux et Analyse</b>	<b>14</b>
<b>5</b>	<b>Conclusion</b>	<b>15</b>

# 1 Introduction

## 1.1 Contexte et objectif

En imagerie médicale, l'ophtalmoscopie à balayage laser (SLO) est une technique qui permet de réaliser des images haute résolution de fond d'oeil. Un traitement poussé de ces images permet ensuite de segmenter le réseau vasculaire de la rétine afin de le rendre plus distinguable et ainsi être en mesure de détecter de potentielles pathologies chez un patient, telles que l'hypertension artérielle ou l'insuffisance rénale.

Le but de ce projet est de mettre au point un algorithme de traitement d'image qui permette d'obtenir une segmentation la plus précise possible du réseau vasculaire d'un fond d'oeil. Cet algorithme doit traiter l'image au travers de diverses méthodes, telles que l'usage de filtres ou d'opérations morphologiques, mais ne doit en aucun cas avoir recours à l'apprentissage machine. L'image ci-dessous présente un fond d'oeil obtenu par SLO, et le réseau vasculaire associé.




FIGURE 1 – Fond d'oeil (a) et réseau vasculaire (b)

## 1.2 Données

Dans le cadre de ce projet, les données à disposition sont issues de la base de données IOSTER de l'IDIAP. Nous disposons de 20 images au total :

- 10 images de **fond d'oeil** en niveaux de gris. Les images ont été obtenues par SLO et sont de dimensions 512x512 pixels. Chaque pixel a une unique valeur entière comprise entre 0 (noir) et 255 (blanc).
- 10 images de **vérité terrain** en noir et blanc. Ces images correspondent à la segmentation du réseau vasculaire des 10 premières images, annotées manuellement par des experts en analyse d'image rétinienne. Ces images sont également de dimensions 512x512 pixels. Chaque pixel a une valeur unique égale à 0 (noir) ou 1 (blanc), les pixels en blanc correspondant au réseau vasculaire à retrouver.

La figure ci-dessous présente le jeu d'image complet à notre disposition.




FIGURE 2 – Jeu de données du projet

### 1.3 Métrique d'évaluation

Afin de mesurer la performance de notre algorithme, il est important de déterminer la métrique qui servira d'évaluateur. Dans le cadre de ce projet, une fonction d'évaluation nous est imposée, et fonctionne de la manière suivante :

- Les 2 images à comparer, celle obtenue par notre algorithme et la vérité terrain associée, sont tout d'abord squelettisées. Cela signifie que les vaisseaux (chaînes de pixels blancs) sont amincis jusqu'à n'en conserver que leur fibre neutre.
- A partir des 4 images ainsi à disposition, 3 variables sont calculées :
  - ◇ Les **vrais positifs (TP)** correspondent au nombre de pixels blancs en commun entre notre image squelettisée et la vérité terrain.
  - ◇ Les **faux positifs (FP)** correspondent au nombre de pixels blancs dans notre image squelettisée ne correspondant pas à des pixels blancs de la vérité terrain.
  - ◇ Les **faux négatifs (FN)** correspondent au nombre de pixels blancs de la vérité terrain squelettisée ne correspondant pas à des pixels blancs dans l'image obtenue par notre algorithme.
- Enfin, cela permet de déterminer 2 métriques d'évaluation de performance de notre algorithme :
  - ◇ La **précision (ACCU)** représente le taux de vrais positifs sur tous les positifs déterminés par notre algorithme, et répond à la question "*A quel point notre algorithme est correct lorsqu'il détecte un vaisseau ?*".

$$ACCU = \frac{TP}{TP + FP}$$

- ◇ Le **rappel (RECALL)** représente le taux de vrais positifs sur tous les positifs de la vérité terrain, et répond à la question "*A quel point notre algorithme détecte les vaisseaux ?*".

$$RECALL = \frac{TP}{TP + FN}$$

- La squelettisation des images permet à notre algorithme de légères erreurs sans impact notable sur sa performance mesurée. L'intérêt principal de la tâche est de détecter un réseau vasculaire, à savoir des vaisseaux et leurs nombreuses interconnexions, ce que la squelettisation n'empêche pas. Il serait en revanche dommage que de légères erreurs, dues au bruit dans l'image d'origine, viennent perturber la performance mesurée, et ainsi nous faire passer à côté de notre objectif.

De plus, nous allons également observer le **F1-score**, qui est un bon indicateur moyen des 2 métriques citées ci-dessus.

$$F1 - SCORE = \frac{2}{\frac{1}{ACCU} + \frac{1}{RECALL}}$$

## 2 Opérations

### 2.1 Augmentation du contraste

La première étape de notre algorithme consiste à augmenter le contraste de l'image par la méthode CLAHE (Contrast Limited Adaptive Histogram Equalization). Cette méthode augmente le contraste de l'image par région afin mieux faire ressortir les vaisseaux. L'augmentation des contrastes étire le range des niveaux de gris pour qu'il s'étende bien sur toute la plage  $[0-255]$ .

Les figures ci-dessous nous montrent les histogrammes des valeurs de gris de l'image avant et après CLAHE, ainsi que les images elles-mêmes avant et après CLAHE.




FIGURE 3 – Histogrammes des niveaux de gris avant (a) et après (b) CLAHE




FIGURE 4 – Images avant (a) et après (b) CLAHE

### 2.2 Filtre de Gabor

L'étape suivante consiste à appliquer un filtre de Gabor. Les vaisseaux sanguins ont une structure tubulaire à orientations multiples, et les filtres de Gabor peuvent être efficaces pour les détecter en mettant en évidence les structures orientées.

La figure ci-dessous nous montre les images avant et après application d'un filtre de Gabor.






FIGURE 5 – Images avant (a) et après (b) filtre de Gabor

## 2.3 Ouvertures

La troisième étape consiste à appliquer une succession d'ouvertures sur l'image et ne conserver que la valeur max pour chaque pixel. Une ouverture est une érosion, qui supprime les petites structures, suivie d'une dilatation, afin de restaurer la taille des structures restantes. L'intérêt ici est d'éliminer le bruit très présent en arrière-plan, tout en préservant les contours des vaisseaux.

Les vaisseaux pouvant être considérés comme des structures longitudinales à orientation multiple, nous créons d'abord une fonction (`generate_footprint`) qui va générer un rectangle de 1x15 pixels, puis le faire pivoter de 0 à 180°. En faisant cela, nous nous assurons que lorsque l'empreinte sera alignée avec le vaisseau, ce dernier sera conservé. Tandis qu'une petite structure (le bruit) sera supprimée car jamais totalement en phase avec l'empreinte malgré ses multiples orientations.

La figure ci-dessous nous présente les différentes empreintes générées qui vont nous servir aux opérations d'ouverture.




FIGURE 6 – Empreintes utilisées pour les ouvertures

La figure ci-dessous nous montre les images avant et après les ouvertures successives. Nous pouvons remarquer que l'arrière-plan est nettement moins bruité qu'auparavant.




FIGURE 7 – Images avant (a) et après (b) ouvertures

## 2.4 Black Top-Hats

Nous appliquons ensuite une succession d'opérations black top-hat et les sommes. Le black top-hat permet de faire ressortir les petits vaisseaux qui se confondent avec l'arrière-plan. L'idée ici est de générer plusieurs structures avec la même fonction que précédemment (cette fois-ci des rectangles de  $1 \times 7$  pixels orientés de  $0$  à  $180^\circ$ ) qui serviront d'empreintes pour les différentes opérations de black top-hat. Le fait d'appliquer cette opération dans des orientations très diverses permet ainsi de mieux distinguer l'entière du réseau vasculaire. Cela permet également d'invertir les niveaux de gris, le réseau devient blanc et l'arrière-plan devient noir, comme le montre la figure ci-dessous.




FIGURE 8 – Images avant (a) et après (b) black top-hats

## 2.5 Erosions

L'opération précédente ayant restauré une partie du bruit précédemment supprimé, la cinquième opération de notre algorithme consiste à appliquer une succession d'érosions sur l'image afin de supprimer le bruit non désiré. Nous reprenons les différentes structures orientées de longueur 15 utilisées pour les ouvertures afin de les utiliser également pour les érosions, puis ne gardons que la valeur max de chaque pixel. Cela nous permet d'obtenir la transformation ci-dessous.



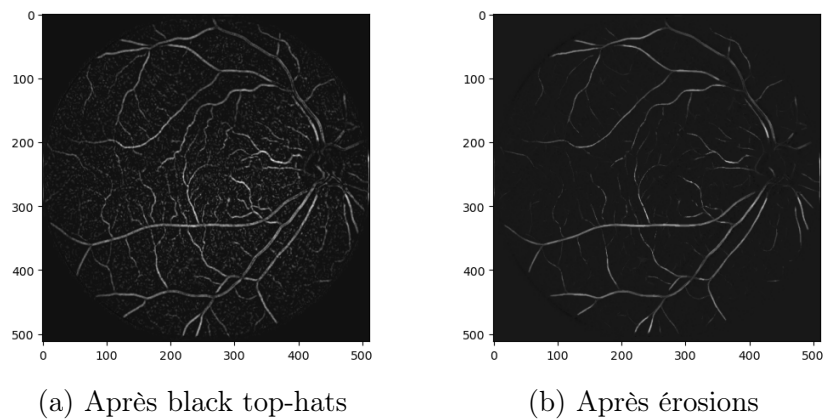


FIGURE 9 – Images avant (a) et après (b) érosions

## 2.6 Reconstruction

L'érosion ayant endommagé le réseau vasculaire, supprimant au passage quelques petits vaisseaux ou interconnexions entre vaisseaux, nous pratiquons ensuite une reconstruction (basée sur la dilatation) de l'image en utilisant l'image après black top-hats comme masque. L'idée est de recouvrir la partie endommagée du réseau vasculaire. L'image ci-dessous nous montre le résultat ainsi obtenu.




FIGURE 10 – Images avant (a) et après (b) reconstruction

## 2.7 Filtre gaussien

Enfin, la dernière étape avant segmentation est l'application d'un filtre gaussien afin de supprimer autant que possible le bruit restant dans l'image.

La figure ci-dessous nous montre les images avant et après l'application du filtre gaussien.




FIGURE 11 – Images avant (a) et après (b) filtre gaussien

## 2.8 Segmentation

Après toutes les étapes de pré-traitement, nous pouvons segmenter l'image par seuillage. L'idée est de binariser l'image et de convertir en noir (valeur = 0) les pixels dont la valeur est inférieure au seuil et en blanc (valeur = 1) ceux dont la valeur est supérieure au seuil. Cela permet d'obtenir l'image finale ci-dessous.

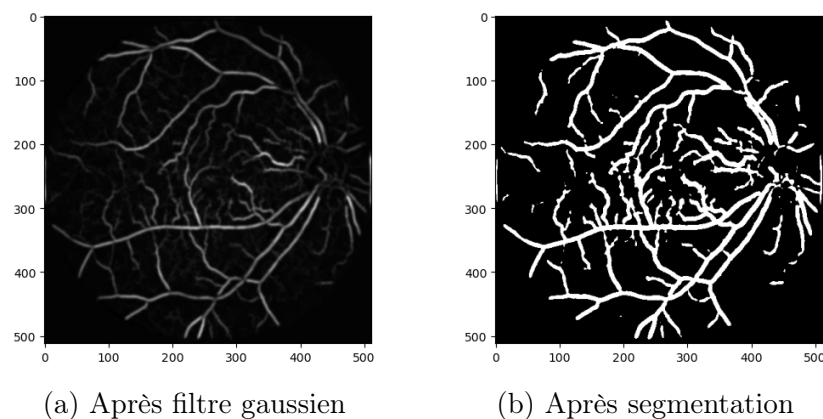


FIGURE 12 – Images avant (a) et après (b) segmentation

## 2.9 Premiers résultats

Après cette première segmentation, nous évaluons la performance de notre algorithme, et obtenons les résultats suivants :

- ◇ **précision : 83.3%**
- ◇ **rappel : 81.9%**
- ◇ **F1-score : 82.4%**

L'image ci-dessous nous montre une superposition de l'image squelettisée de la vérité terrain (en rouge) sur l'image obtenue par notre algorithme. Notre algorithme permet de recouvrir une grande partie du réseau vasculaire, sans ajouter trop de faux-positifs. Les parties du réseau non recouvert se situent principalement aux extrémités, là où les vaisseaux sont les plus fins et les moins distinguables dans l'image de fond d'oeil originale.




FIGURE 13 – Image segmentée (blanc) VS vérité terrain (rouge)

Cette première passe sur l'algorithme n'a été réalisée que sur une image du dataset à notre disposition. La performance obtenue n'est donc pas suffisamment représentative pour être généralisée. De plus, les paramètres utilisés dans les différentes opérations présentées ci-dessus ont été déterminés empiriquement, une approche plus méthodique s'avère pertinente afin d'optimiser ces paramètres.

## 3 Optimisations

### 3.1 Méthodologie initiale pour l'optimisation : Affinage des Hyperparamètres avec Optuna

Dans nos premières étapes d'optimisation, nous avons choisi de nous concentrer sur l'analyse d'une seule image pour mieux comprendre l'effet de chaque paramètre sur la qualité de la segmentation. Pour cela, nous avons utilisé Optuna, un outil d'optimisation automatique qui utilise des techniques d'optimisation bayésienne pour explorer efficacement l'espace des paramètres et identifier les combinaisons les plus performantes. Optuna vise à minimiser la fonction objectif, donc, pour maximiser notre score F1, nous avons configuré Optuna pour minimiser le score F1 négatif (-F1 Score), permettant ainsi une recherche directe des paramètres optimisant la performance de notre algorithme.

### 3.2 Considérations sur le choix des hyperparamètres

Dans le cadre de notre démarche d'optimisation avec Optuna, nous avons décidé de limiter le nombre d'hyperparamètres à ajuster. Cette approche visait à optimiser l'efficacité de la convergence vers les paramètres optimaux. En effet, augmenter outre mesure le nombre d'hyperparamètres peut complexifier excessivement l'espace de recherche, ralentissant le processus d'optimisation et réduisant la probabilité de trouver une solution optimale dans un temps raisonnable.

Les hyperparamètres que nous avons sélectionnés pour l'optimisation étaient les suivants :

- **clip\_limit** : Ce paramètre ajuste le seuil de contraste dans la méthode CLAHE, prévenant ainsi une amplification du bruit dans les régions homogènes de l'image.
- **gabor frequency** : Ce paramètre influence la fréquence du filtre de Gabor, crucial pour mettre en évidence les structures linéaires et orientées telles que les vaisseaux sanguins.
- **sigma** : Sigma détermine l'écart-type dans l'application du filtre gaussien, utilisé pour adoucir l'image après reconstruction tout en préservant les contours essentiels des vaisseaux.
- **seuil** : Ce paramètre est essentiel pour la segmentation binaire finale, distinguant les pixels appartenant aux vaisseaux de ceux du fond.

La limitation à ces hyperparamètres visait à focaliser notre optimisation sur les éléments clés du processus de segmentation. Cela a permis d'explorer de façon méthodique et approfondie l'espace des paramètres pertinents sans surcharger Optuna de variables inutiles, pouvant diminuer l'efficacité de l'optimisation.

### 3.3 Affinage progressif des hyperparamètres

La méthodologie d'optimisation avec Optuna a impliqué une approche itérative et réfléchie pour définir le domaine de recherche des valeurs des hyperparamètres. Initialement, nous avons attribué à chaque paramètre un intervalle relativement large, permettant à Optuna d'explorer un vaste espace de solutions potentielles. Cette première phase était cruciale pour obtenir une compréhension générale de l'influence de chaque paramètre sur les performances de notre algorithme.

Cependant, la définition d'intervalles trop étendus peut se révéler contre-productive, car elle risque de disperser l'effort d'optimisation et de ralentir la convergence vers les valeurs optimales. Pour pallier cela, nous avons adopté une stratégie d'affinage progressif : suite aux résultats préliminaires obtenus, nous avons resserré les intervalles de recherche autour des valeurs les plus prometteuses. Ce processus d'ajustement a été répété, en réduisant progressivement la gamme des valeurs possibles pour chaque paramètre, tout en maintenant une flexibilité suffisante pour découvrir les combinaisons les plus efficaces.

Cette approche a permis d'augmenter significativement l'efficacité de l'optimisation, en concentrant les efforts d'Optuna sur les régions de l'espace des paramètres les plus susceptibles de contenir la solution optimale.

### 3.4 Résultats

Suite à l'optimisation réalisée avec Optuna, nous avons pu définir un jeu de paramètres optimal pour l'image star32 ODC :

- Limite de Contraste (Clip Limit) : 0.009
- Sigma : 0.574
- Fréquence de Gabor (Frequency) : 0.779
- Seuil : 199

L'application de ces paramètres a permis d'augmenter significativement la précision de notre segmentation, atteignant un F1-score de 83.5% (contre 82.4% initialement), une précision de 86.4% et un rappel de 80.9%. Ces améliorations démontrent une distinction plus nette des vaisseaux sanguins dans l'image traitée et une diminution notable du bruit résiduel.

### 3.5 Exploration et Tests de Méthodes Supplémentaires

Après avoir optimisé les hyperparamètres de notre algorithme de segmentation, nous avons cherché à explorer d'autres méthodes susceptibles d'améliorer encore les résultats. Nous avons expérimenté plusieurs techniques, chacune visant à affiner davantage la segmentation ou à améliorer la distinction entre les vaisseaux sanguins et l'arrière-plan de l'image.

- **Contraste local avec Clahe** : Nous avons tenté d'introduire un ajustement de contraste local en utilisant l'algorithme CLAHE, dans l'espoir d'améliorer la visibilité des vaisseaux les plus fins. Cependant, cette méthode n'a pas conduit à une amélioration significative des résultats, probablement en raison de l'augmentation du bruit dans certaines régions de l'image.
- **Filtrage par Frangi** : L'application du filtre Frangi, conçu spécifiquement pour l'extraction de structures vasculaires, était une autre piste que nous avons explorée. Bien que théoriquement prometteuse pour notre cas d'usage, cette technique n'a pas apporté l'amélioration escomptée, possiblement à cause de la sensibilité de l'algorithme aux paramètres spécifiques de notre ensemble de données.
- **Segmentation à seuil adaptatif** : Envisageant une approche de segmentation plus dynamique, nous avons testé une segmentation à seuil adaptatif, qui ajuste le seuil de binarisation en fonction des variations locales de luminosité. Cette méthode

n'a pas non plus conduit à des améliorations notables, suggérant que la complexité ajoutée ne compensait pas les avantages potentiels pour nos images spécifiques.

- **Ré-application de la segmentation** : Dans les zones où les vaisseaux sanguins n'étaient pas clairement identifiés, nous avons testé une ré-application de la segmentation, en ajustant potentiellement les paramètres ou en appliquant des pré-traitements ciblés à ces régions spécifiques. Cette approche avait pour but d'affiner la segmentation dans les zones problématiques, sans perturber les parties de l'image où la segmentation était déjà satisfaisante. Malheureusement, cette méthode n'a pas non plus conduit à une amélioration significative des résultats, soulignant les défis inhérents à l'identification précise des vaisseaux les plus fins ou les moins contrastés.

### 3.6 Post-traitement et amélioration finale

Suite à ces tentatives, nous avons décidé d'introduire des étapes de post-traitement pour affiner les résultats de la segmentation. Les techniques choisies pour le post-traitement étaient principalement axées sur la correction des imperfections résiduelles et l'amélioration de la cohérence globale de la segmentation.

Nous avons rajouté deux étapes de post-traitement, le filtrage des composantes connectées et l'optimisation de la dilatation. Cela a finalement conduit à une amélioration des résultats. Le meilleur F1-score atteint était de 85.8%, démontrant l'efficacité du post-traitement dans l'amélioration de la qualité de la segmentation.

### 3.7 Extension de l'Optimisation aux Autres Images

Après avoir optimisé les hyperparamètres pour une image spécifique, nous avons évalué l'efficacité de ces paramètres sur l'ensemble des images de notre jeu de données. Nous avons observé des variations significatives dans les scores F1 entre les images, mettant en évidence la variabilité de la performance de notre algorithme en fonction des caractéristiques spécifiques de chaque image. Par exemple, alors que l'image `star32_ODC.jpg` a atteint un F1-score de 85.8% avec les paramètres optimisés, le même ensemble de paramètres a produit un score de seulement 75% sur l'image `star21_OSC.jpg`.

Cette disparité nous a conduit à reconsidérer notre approche d'optimisation. Nous avons décidé d'optimiser aussi sur l'image présentant le score F1 le plus bas, dans le but d'améliorer la robustesse de notre algorithme sur les cas les plus difficiles. En ciblant l'image `star21_OSC.jpg`, nous avons finalement obtenu les paramètres et score suivants après une nouvelle optimisation avec Optuna :

Image	F1 Pre-Processing	F1 Post-Processing	Cl Limit	Sigma	Freq	Seuil
<code>star21_OSC.jpg</code>	76.1%	78.1%	0.01	1.27	0.784	213
<code>star32_ODC.jpg</code>	83.6%	85.8%	0.009	0.574	0.779	199

TABLE 1 – F1-scores avant et après post-traitement avec paramètres optimaux pour `star21` et `star32`

### 3.8 Optimisation Globale des Hyperparamètres

Pour généraliser l'efficacité de notre algorithme à l'ensemble du dataset, nous avons orienté notre stratégie d'optimisation vers la maximisation du score F1 moyen. Cette



démarche impliquait l’ajustement des hyperparamètres non plus pour une image isolée, mais dans le but d’améliorer la performance globale de segmentation sur toutes les images.

En s’appuyant sur les résultats précédemment obtenus pour les images ayant présenté les meilleures et les moins bonnes performances, nous avons défini de nouveaux intervalles pour les hyperparamètres dans Optuna. Cette méthode avait pour but de cerner plus précisément l’espace de recherche, en prenant en compte la variabilité des images du dataset.

L’objectif était de parvenir à un compromis, où les paramètres sélectionnés seraient suffisamment versatiles pour traiter efficacement les diverses caractéristiques présentes dans l’ensemble des images. Cette optimisation globale visait ainsi à renforcer la capacité de notre algorithme à s’adapter aux variations inhérentes aux images de fond d’œil, en garantissant une performance constante et élevée sur l’intégralité du dataset.

## 4 Résultats finaux et Analyse

Nous avons atteint un ensemble de paramètres qui optimisent la performance de notre algorithme de segmentation sur un ensemble diversifié d’images de fond d’œil. Ces paramètres ont été choisis pour maximiser la moyenne des scores F1 sur l’ensemble de notre dataset, reflétant un équilibre entre les performances individuelles sur chaque image et la cohérence globale de l’algorithme.

La table suivante présente les paramètres globaux qui ont abouti à la meilleure moyenne de score F1, soulignant l’importance de chaque paramètre dans l’amélioration de la qualité de la segmentation.

Paramètre	Valeur
Meilleure moyenne de score F1	82.1%
clip_limit	0.011
sigma	1.233
frequency	0.831
seuil	194

TABLE 2 – Paramètres globaux pour la meilleure moyenne de score F1 après mise à jour

Afin de détailler davantage les performances, nous avons également compilé les scores F1 obtenus pour chaque image du dataset, comme indiqué dans la table suivante. Cette approche nous permet de constater les variations de performance et de mieux comprendre comment les paramètres optimisés agissent sur des images spécifiques.

Il est intéressant de noter que, bien que certains scores F1 spécifiques à l’image puissent être légèrement inférieurs à ceux obtenus lors d’optimisations individuelles, l’objectif de cette démarche était de parvenir à une performance homogène et élevée à travers l’ensemble du dataset. Cette stratégie assure que l’algorithme reste robuste et fiable, indépendamment des variations intrinsèques entre les différentes images.

Image	F1 Score correspondant
star01_OSC.jpg	84.9%
star02_OSC.jpg	84.5%
star03_OSN.jpg	80.9%
star08_OSN.jpg	84.1%
star21_OSC.jpg	77.8%
star26_ODC.jpg	80.8%
star28_ODN.jpg	79.8%
star32_ODC.jpg	84.9%
star37_ODN.jpg	83.0%
star48_OSN.jpg	85.2%

TABLE 3 – F1-scores correspondant par image après optimisation globale et mise à jour

## 5 Conclusion

Ce projet a représenté un défi stimulant et instructif dans le domaine de la vision par ordinateur et de la segmentation d'images médicales, en utilisant une méthodologie rigoureuse sans recourir à l'apprentissage automatique.

Notre approche a consisté à combiner une série d'opérations de traitement d'image, allant de l'augmentation du contraste à l'utilisation de filtres spécifiques comme le filtre de Gabor, et enfin à des techniques morphologiques. Nous avons systématiquement optimisé les hyperparamètres de notre algorithme à l'aide d'Optuna, un framework d'optimisation avancée, pour maximiser le F1 Score de notre segmentation. Cette démarche nous a permis de comprendre l'impact significatif de chaque paramètre sur la qualité finale de la segmentation.

En explorant différentes méthodes pour améliorer nos résultats, nous avons appris que l'ajout de techniques supplémentaires n'améliorait pas toujours les performances. Cela nous a enseigné l'importance de la simplicité et de la précision dans le choix de nos méthodes de traitement d'image.

L'optimisation des hyperparamètres pour une image spécifique a révélé des variations dans les performances à travers le dataset, ce qui nous a conduit à adopter une stratégie d'optimisation globale. Cette approche visait à trouver un équilibre optimal permettant d'obtenir des performances homogènes sur l'ensemble des images. Les résultats finaux ont démontré la robustesse et la fiabilité de notre algorithme, avec un F1-score moyen satisfaisant de 82.1%.

Ce projet a souligné l'importance de l'optimisation soignée des hyperparamètres et du choix judicieux des techniques de traitement d'image dans la segmentation des images médicales.